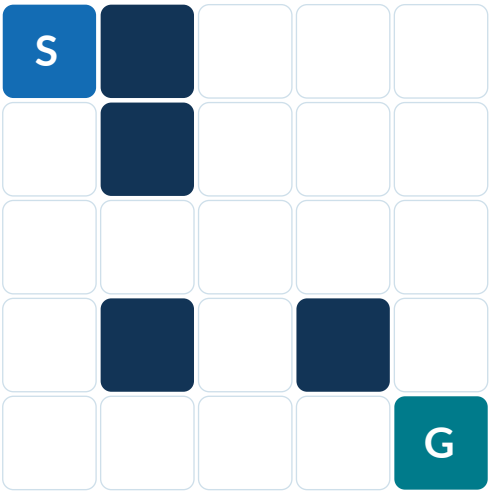
Od ruchu do decyzji

Nie chodzi o zakodowanie drogi przez labirynt. Chodzi o nauczenie agenta, które decyzje są opłacalne.

Wasz eksperyment: plansza 5 × 5, cztery ruchy, ściany, wyjście i nagrody. Środowisko jest gotowe; szukacie reguły podejmowania decyzji, a nie gotowej sekwencji współrzędnych.

ŚRODOWISKO: CO NAPRAWDĘ WIDZI AGENT?

MAPA ŚRODOWISKA



S = przykładowy start • G = cel
ciemne pola = ściany

CZEGO AGENT NIE DOSTAJE?

- **Stan**
  To jedna pozycja (wiersz, kolumna), nie historia trasy.
- **Akcja**
  Jeden z czterech kierunków, także gdy ruch okaże się zły.
- **Informacja zwrotna**
  Po wykonaniu ruchu zna nowy stan i nagrodę.
- **Epizod**
  Osobna próba. Kończy się sukcesem albo limitem 50 ruchów.

SYGNAŁ NAGRODY NIE JEST NAWIGACJĄ GPS

+10	−0,1	−1
Cel	**Ruch**	**Blokada**
nagroda na końcu	koszt każdego kroku	brak zmiany pozycji

ZANIM NAPISZECIE PIERWSZĄ FUNKCJĘ

Dlaczego kara za każdy poprawny ruch może sprzyjać krótszym trasom? Czy agent otrzymuje wprost informację, który kierunek jest optymalny? I czy dwa epizody z różnych pól startowych powinny mieć taką samą sumę nagród?

Jak powstają wartości Q?

Jedna tablica, dwie strategie wyboru akcji i poprawianie oszacowań po każdym ruchu.

Nie mylcie **wartości akcji** z pewnością, że ruch jest poprawny. Q(s, a) to oszacowanie przyszłej sumy zdyskontowanych nagród, a nie rozkaz ani zapamiętana ścieżka.

CZTERY OCENY DLA JEDNEGO POLA

↑	→	↓	←
−0,2	0,4	0,4	−1,0

Dwie akcje mają takie samo maksimum. Co zrobi algorytm, jeśli ε = 0?

POLITYKA ε-ZACHŁANNA

ε: szukaj nowych ruchów

1 − ε: korzystaj z Q

Losowy wybór może również wskazać najlepszą akcję. Dlatego ε to nie zawsze odsetek gorszych ruchów.

AKTUALIZACJA: POPRAWIAJ JEDNĄ OCENĘ, NIE CAŁĄ MAPĘ

$$Q(s,a) \leftarrow Q(s,a) + \alpha \cdot [r + \gamma \cdot V(s') - Q(s,a)]$$

Stara ocena + **część błędu przewidywania**. V(s′) oznacza najwyżej ocenioną akcję w nowym stanie — poza prawdziwym końcem zadania.

α = 0,1 / TEMPO UCZENIA

Jak szybko nowa obserwacja zmienia starą ocenę? Gdy α jest bardzo małe, adaptacja może być powolna; gdy duże, aktualizacje mogą mocno reagować na pojedyncze przejścia.

γ = 0,95 / PRZYSZŁOŚĆ

Jak ważne są przyszłe nagrody? Małe γ koncentruje agenta na tym, co tu i teraz. Duże pozwala oceniać ruch przez pryzmat dalszej drogi do celu.

PUŁAPKA POJĘCIOWA: DWA RODZAJE KOŃCA

Dotarcie do celu kończy zadanie. **Wyczerpanie limitu 50 kroków** kończy próbę, ale nie oznacza osiągnięcia celu. Zastanówcie się, kiedy prognoza przyszłej nagrody rzeczywiście powinna zniknąć.

Od pojedynczego ruchu do eksperymentu

Pętla programu wydaje się prosta. Najwięcej błędów powstaje jednak na granicach między etapami.

W notebooku są gotowe środowisko, testy oraz BFS do sprawdzania osiągalności (nie do sterowania agentem). Uzupełniacie sześć bloków. Jak przepływają między nimi dane?

ANATOMIA JEDNEGO KROKU

Stan s → **Decyzja** a → **Środowisko** s′, r → **Ocena** Q

SZEŚĆ MIEJSC, W KTÓRYCH TRZEBA PODJĄĆ DECYZJĘ

TODO 1 — Pamięć wartości

Jak powinna wyglądać struktura o jednej ocenie na każdą parę: pole–kierunek?

TODO 2 — Polityka wyboru

Kiedy losować dowolną akcję, a kiedy losować tylko spośród najlepszych?

TODO 3 — Uczenie z nagrody

Który konkretnie element pamięci powinien zostać zmieniony po przejściu?

TODO 4 — Życie epizodu

Które dane są „przed”, a które „po” ruchu? Co kończy pętlę?

TODO 5 — Zamrożony test

Jak zmierzyć wyuczoną strategię, nie modyfikując jej podczas pomiaru?

TODO 6 — Uczciwa miara

Czy średnia liczba kroków ma sens, jeśli żaden test nie zakończył się sukcesem?

Klucz: uczenie zachodzi w trakcie prób treningowych, natomiast pomiar końcowej strategii ma odpowiedzieć na inne pytanie niż trening.

Debugowanie bez zgadywania

Zamiast zmieniać pięć parametrów naraz, wyizoluj jeden objaw i jedną hipotezę.

Błąd w Q-learningu nie zawsze kończy się wyjątkiem. Częściej dostaniecie „działający” program, który niczego się nie nauczył. Poniżej są tropy, nie gotowe poprawki.

01 Testy nie przechodzą

Objaw: komórka zatrzymuje się przed treningiem.

Sprawdź: Która najprostsza niezmiennicza własność funkcji jest łamana?

02 Agent ma jeden „ulubiony” ruch

Objaw: przy równych wartościach Q stale wybiera ten sam kierunek.

Sprawdź: Czy remis to na pewno to samo co unikalne maksimum?

03 Wykres prawie się nie zmienia

Objaw: Q pozostaje blisko zer albo poprawia się bardzo rzadko.

Sprawdź: Czy wykonany ruch rzeczywiście uruchamia aktualizację?

04 Agent odbija się od ścian

Objaw: pozycja się nie zmienia, lecz liczba ruchów rośnie.

Sprawdź: Czy rozróżniacie próbę ruchu od zmiany współrzędnych?

05 Wynik zależy od kolejności komórek

Objaw: ten sam notebook daje inne wyniki po częściowym uruchomieniu.

Sprawdź: Czy używacie aktualnych definicji funkcji i świeżej tablicy Q?

06 Na końcu epizodu coś się nie zgadza

Objaw: cel na ostatnim ruchu jest traktowany jak porażka.

Sprawdź: Jaka jest kolejność: krok, ocena końca, zapis wyniku?

07 Agent „uczy się” podczas testu

Objaw: kolejny test wypada inaczej niż poprzedni.

Sprawdź: Co mogło się zmienić między dwoma pomiarami?

08 Średnie wyglądają znakomicie

Objaw: kroki niskie, ale większość prób nie kończy się sukcesem.

Sprawdź: Jakie próby weszły do mianownika każdej metryki?

Eksperyment, pomiar i wnioski

Działający kod to początek. Dopiero poprawny eksperyment mówi, czego agent się nauczył.

Agent losowy jest punktem odniesienia; Q-learning aktualizuje swoje oceny, a BFS tylko wyznacza długość najkrótszej drogi. Nie mylcie trzech pytań: **czy kod działa?**, **czy uczenie zaszło?**, **czy porównanie jest uczciwe?**

300 epizodów treningu	**20** wspólnych pól testowych	**50** maksymalnie ruchów

TRZY OBSERWACJE, TRZY RÓŻNE ZNACZENIA

Suma nagród	Może rosnąć, ale zależy od losowych decyzji i odległości startu od celu.
Skuteczność	Udział sukcesów we wszystkich 20 próbach — również nieudanych.
Kroki w sukcesach	Średnia tylko z udanych przejść; podajcie również liczbę tych przejść.

NIE MYLCIE TRENINGU Z OCENĄ

W czasie treningu eksploracja jest potrzebna; w teście chcecie ocenić już wypracowane decyzje. Pomyślcie, co powinno być niezmienne podczas porównania agenta losowego i wyuczonego. Uwaga: nawet bez eksploracji pozostaje kwestia remisów Q.

MINIMALNY ŚLAD DO DEBUGOWANIA

```
stan | akcja | nowy stan | nagroda | koniec? | Q przed/po
```

Zapisz kilka przejść i sprawdź je ręcznie, zanim zaufasz wykresowi 300 epizodów.

Pytanie na koniec: jeśli dwie strategie mają podobną skuteczność, lecz jedna w udanych próbach chodzi krócej — czy można już ogłosić zwycięzcę? Co jeszcze trzeba sprawdzić?